


Analisis Ekosistem *Big Data Multi-Platform* untuk Korelasi Sentimen Konsumen dan Penjualan *Smartphone* di Indonesia

Oleh : Nadia Raissa Romadhoni

Perkembangan teknologi digital mengubah perilaku konsumen dalam memilih *smartphone*. Perilaku konsumen kini dipengaruhi oleh beberapa aspek media sosial, salah satunya adalah review kreator YouTube, jumlah yang laku di pasaran, dan komentar pengguna lain, yang mana bukan hanya berdasarkan spesifikasi dan harga produk. *Marketplace* seperti Shopee, Lazada, dan Tokopedia menghasilkan data penjualan, harga, dan lain-lain dalam skala besar. Di sisi lain, YouTube menghasilkan ribuan komentar yang mencerminkan opini konsumen terhadap produk. Fenomena ini membentuk ekosistem *big data multi-platform* yang kompleks dengan *volume* besar, beragam format, dan memungkinkan perubahan cepat. Menariknya, sentimen positif belum tentu berkorelasi dengan penjualan tinggi, beberapa produk bersentimen negatif justru laku di pasaran karena harga atau promosi. Penelitian ini menggunakan data dari Shopee, Lazada, Tokopedia, dan YouTube dengan total 11.849 data bersih untuk menganalisis hubungan tersebut menggunakan NLP dan visualisasi hasil.



1. *Volume*

Dataset berjumlah 11.849 data bersih setelah *preprocessing* dengan jumlah 4.437 produk dari tiga marketplace (Shopee: 1.015, Lazada: 3.066, Tokopedia: 546 data valid) dan 7.412 komentar YouTube dari empat video *channel review* gadget Indonesia. *Volume* ini jauh lebih representatif dibandingkan dengan survei konvensional dan volume ini memungkinkan analisis distribusi *brand* secara statistik yang lebih komprehensif.

2. *Velocity*

Data *marketplace* dan YouTube bersifat dinamis. Harga dan jumlah penjualan dapat berubah mengikuti tren peluncuran produk baru dan periode tertentu, sedangkan komentar YouTube dapat bertambah saat audiens mungkin membutuhkan *review smartphone* dan ketika video viral. Namun, untuk sistem saat ini menggunakan data statis yang dikumpulkan pada satu waktu, dan untuk pengembangan ke depannya, penelitian dapat membutuhkan pipeline pembaruan berkala agar insight tetap relevan dengan kondisi terkini.

3. *Variety*

Pada proyek ini, tiga jenis data digabungkan, yaitu teks tidak terstruktur sebanyak 7.412 komentar YouTube yang diproses melalui 4 tahap NLP, yaitu: *cleaning*, normalisasi, tokenisasi, stemming Sastrawi, numerik seperti kolom harga dan jumlah terjual, dan juga kategorikal berupa brand, platform, segmen harga. Kolom YouTube bertambah dari 6 menjadi 19 setelah *preprocessing*. Hal ini mencerminkan *variety* yang berkembang.

4. *Veracity*

Tantangan utama dari data *e-commerce* mengandung 226 duplikat lintas platform, outlier harga ekstrem (maks. Rp39,25 juta sebelum *cleaning*), dan 532 produk non-HP (aksesori, casing, dan produk non-smartphone lainnya).

Data YouTube mengandung 28 duplikat dan 283 komentar terlalu pendek. Semua diselesaikan melalui *deduplication*, *clip outlier* IQR (data tidak hilang), *filter keyword*, dan kamus normalisasi 80+ kata alay. Dengan hasil akhir *missing value* = 0, duplikat = 0 pada kedua dataset.

5. Variability

Pola komentar YouTube bervariasi berdasarkan waktu dan konteks. Komentar pada video *unboxing* cenderung lebih antusias sehingga menghasilkan lebih banyak komentar positif, sedangkan video "setelah 6 bulan pakai" menghasilkan komentar yang lebih kritis dan nuansatif. Distribusi *brand* juga tidak merata, dimana pada *channel* Gadgetin mendominasi 65% data YouTube, sehingga analisis menggunakan *weighted sentiment* (bobot berdasarkan log jumlah komentar) untuk menangani variabilitas *volume* antar *brand*.

6. Validity

Validitas analisis sentimen ditingkatkan melalui dua pendekatan, yaitu rule-based model sebagai baseline dan model RoBERTa yang memahami konteks bahasa Indonesia informal. Perbandingan kedua model menggunakan confusion matrix, akurasi, *precision*, *recall*, dan *F1-score* untuk memastikan klasifikasi sentimen yang andal. *Weighted sentiment* digunakan untuk menghindari bias akibat ketidakseimbangan jumlah komentar antar brand.

7. Value

Integrasi data menghasilkan empat *insight* bisnis utama, yaitu:

- 1) *Composite score ranking brand* berdasarkan sentimen, penjualan, rating, dan nilai harga;
- 2) Korelasi antara *weighted sentiment* dan total penjualan;
- 3) Gap analysis 4 kuadran *brand overrated* (seperti sentimen tinggi, dan penjualan rendah) vs *underrated* (seperti sentimen rendah, dan penjualan tinggi);
- 4) Hubungan harga vs rating untuk menguji asumsi bahwa 'mahal = bagus'. Insight ini langsung dapat digunakan sebagai dasar strategi pemasaran berbasis data.

Dengan penelitian ini, untuk hasil yang lebih komprehensif dan efektif, disarankan adanya pengembangan penelitian dengan membangun pipeline data real-time berbasis Apache Kafka atau *scheduled scraping* agar *dashboard* otomatis diperbarui mengikuti perubahan harga, rating, dan komentar baru. Lalu, mengembangkan *aspect-based sentiment analysis* untuk mengetahui opini konsumen pada aspek spesifik seperti kamera, baterai, dan performa *gaming* sejenisnya, yang mana pada penelitian yang sekarang ini, hanya analisis sentiment secara keseluruhan. Dan yang terakhir, yaitu menambahkan *predictive analytics* berbasis pola sentimen historis untuk memprediksi tren penjualan *smartphone* di masa mendatang.

Dengan ini, ekosistem *big data multi-platform* yang mengintegrasikan 11.849 data dari Shopee, Lazada, Tokopedia, dan YouTube mampu memberikan insight mendalam mengenai hubungan sentimen konsumen dan performa penjualan *smartphone*. Ketujuh aspek Big Data (7V) terpenuhi secara nyata dalam project ini, dengan penanganan *veracity* yang terukur dan analisis sentimen berbasis ROBERTA yang valid. Dengan pengembangan pipeline *real-time* dan *aspect-based sentiment*, sistem ini berpotensi menjadi solusi *business intelligence* yang mendukung pengambilan keputusan berbasis data.